

Отчет о проверке

Совпадения

6.94%




Оригинальность

93.06%




Цитирования

0%



Самоцитирования

0%



Совпадения — фрагменты проверяемого текста, полностью или частично сходные с найденными источниками, за исключением фрагментов, которые система отнесла к цитированию или самоцитированию. Показатель «Совпадения» – это доля фрагментов проверяемого текста, отнесенных к совпадениям, в общем объеме текста.

Самоцитирования — фрагменты проверяемого текста, совпадающие или почти совпадающие с фрагментом текста источника, автором или соавтором которого является автор проверяемого документа. Показатель «Самоцитирования» – это доля фрагментов текста, отнесенных к самоцитированию, в общем объеме текста.

Цитирования — фрагменты проверяемого текста, которые не являются авторскими, но которые система отнесла к корректно оформленным. К цитированиям относятся также шаблонные фразы; библиография; фрагменты текста, найденные модулем поиска «СПС Гарант: нормативно-правовая документация». Показатель «Цитирования» – это доля фрагментов проверяемого текста, отнесенных к цитированию, в общем объеме текста.

Текстовое пересечение — фрагмент текста проверяемого документа, совпадающий или почти совпадающий с фрагментом текста источника.

Источник — документ, проиндексированный в системе и содержащийся в модуле поиска, по которому проводится проверка.

Оригинальный текст — фрагменты проверяемого текста, не обнаруженные ни в одном источнике и не отмеченные ни одним из модулей поиска. Показатель «Оригинальность» – это доля фрагментов проверяемого текста, отнесенных к оригинальному тексту, в общем объеме текста.

Обращаем Ваше внимание, что система находит текстовые совпадения проверяемого документа с проиндексированными в системе источниками. При этом система является вспомогательным инструментом, определение корректности и правомерности совпадений или цитирований, а также авторства текстовых фрагментов проверяемого документа остается в компетенции проверяющего.

Параметры проверки


Выполнена проверка с учетом редактирования	Да 
Исключение элементов документа из проверки	Нет 
OCR	Нет 
Структурный анализ	Да 

Интернет Плюс, Цитирование, Шаблонные фразы, Публикации РГБ (переводы и перефразирования), Кольцо вузов, Публикации РГБ, Переводные заимствования по коллекции Гарант: аналитика, ИПС Адилет, СМИ России и СНГ, Диссертации НББ, Перефразирования по коллекции IEEE, Перефразированные заимствования по коллекции Интернет в русском сегменте, Патенты СССР, РФ, СНГ, IEEE, Коллекция НБУ, СПС ГАРАНТ: аналитика, Публикации eLIBRARY (переводы и перефразирования), Публикации eLIBRARY, СПС ГАРАНТ: нормативно-правовая документация, Медицина, Переводные заимствования по коллекции Интернет в русском сегменте, Сводная коллекция ЭБС, Переводные заимствования IEEE, Перефразирования по СПС ГАРАНТ: аналитика, Кольцо вузов (переводы и перефразирования), Переводные заимствования по коллекции Интернет в английском сегменте, Перефразированные заимствования по коллекции Интернет в английском сегменте, Собственная коллекция компании*

Информация о документе

Название документа:	Khadzhynova_Savchits_Zemlyanik_Khadzhinov_S.pdf	Тип файла:	PDF
Система проверки:	Antiplagius	Символов:	9 535
№ отчета:	9844824	Слов:	1 370
Дата проверки:	01.04.2026	Предложений:	94

Основные показатели

Уникальность	Заимствования	Цитирования	Самоцитирования	Оригинальность
				

Модули проверки

- Интернет
- Цитирование
- Кольцо вузов
- eLIBRARY
- СМИ
- Патенты
- Диссертации РГБ
- Научная электронная библиотека
- Энциклопедии
- Переводы
- Рерайт и обход

Уникальность

Уникальность:

93%

Заимствования:

7%

Символов в тексте:

9 535

Слов в тексте:

1 370

Предложений:

94

Заимствования				Найдено источников: 10
№	Источник	Процент	Действия	
1	dokumen.pub https://dokumen.pub/download/a089825f4b9cf254b72e82a3a49386a9.html Интернет	2.76%	Подробнее	
2	dokumen.pub https://dokumen.pub/download/a089825f4b9cf254b72e82a3a49386a9.html Интернет	2.76%	Подробнее	
3	dokumen.pub https://dokumen.pub/download/a089825f4b9cf254b72e82a3a49386a9.html Интернет	2.76%	Подробнее	
4	dokumen.pub https://dokumen.pub/download/a089825f4b9cf254b72e82a3a49386a9.html Интернет	2.76%	Подробнее	
5	dokumen.pub https://dokumen.pub/download/a089825f4b9cf254b72e82a3a49386a9.html Интернет	2.76%	Подробнее	
6	link.springer.com https://link.springer.com/article/10.1007/s41095-018-0116-x Интернет	4.48%	Подробнее	

№	Источник	Процент	Действия
7	francis-press.com https://francis-press.com/papers/18719 Интернет	2.39%	🔗 Подробнее
8	link.springer.com https://link.springer.com/article/10.1007/s41095-018-0116-x Интернет	4.48%	🔗 Подробнее
9	link.springer.com https://link.springer.com/article/10.1007/s41095-018-0116-x Интернет	4.48%	🔗 Подробнее
10	scholar.google.co.cr https://scholar.google.co.cr/citations?user=p2f_-EcAAAAJ&hl=es Интернет	2.42%	🔗 Подробнее

Текст документа

УДК 004 932 2 629 3 05 РАЗРАБОТКА АЛГОРИТМА ДЕТЕКЦИИ СВЕТОФОРОВ И РАСПОЗНАВАНИЕ ИХ СИГНАЛОВ ДЛЯ АВТОНОМНОГО ТРАНСПОРТА Аннотация В статье рассматривается разработка легковесной модели детекции и классификации сигналов светофора для интеграции в систему автономного вождения ADAS Представлено полное описание последовательности обработки видеопотока методов компенсации дисбаланса классов и архитектуры системы на основе YOLOv8 Проведена оценка качества на агрегированном датасете продемонстрировавшая высокую точность работы алгоритма Результаты могут быть использованы для оптимизации ИТ решений в автомобильной промышленности Ключевые слова детекция светофоров автономный автомобиль компьютерное зрение YOLO дисбаланс классов машинное обучение Введение Детекция светофоров и точное распознавание их сигналов являются критически важными компонентами системы восприятия мозга автономного автомобиля В контексте оценки дорожной ситуации светофоры выступают ключевым регулятором проезда перекрестков Данная задача отличается высокой сложностью из за малого относительного размера объектов в кадре изменчивых погодных условий перекрытий и сильных визуальных искажений засветка блики Для обеспечения безопасности стандартов ADAS автомобилю необходимо не только фиксировать красный сигнал но и уверенно распознавать разрешающие фазы для своевременного маневрирования Целью данной работы является разработка и оптимизация нейросетевой модели детекции светофоров способной функционировать в реальном времени на бортовом вычислителе Детекция и распознавание сигналов светофоров представляют собой ключевое звено в системе восприятия автономного автомобиля требующее одновременной точности по локализации

устойчивости к внешним факторам и высокой скорости обработки В данной работе рассматривается возможность построения компактного и производительного алгоритма ориентированного на работу в реальных дорожных условиях Постановка задачи и обзор датасетов На вход системы подается видеопоток с фронтальной камеры автомобиля Алгоритм должен локализовать светофор определить ограничивающую рамку определить тип сигнала осуществить межкадровый трекинг и передать результат в модуль принятия решений Для обучения использовалась агрегированная выборка включающая открытые датасеты Bosch Small Traffic Lights Dataset BSTLD и LISA Traffic Light Dataset а также собственные данные для покрытия сложных условий ночь блики В таблице 1 представлено сравнение использованных открытых наборов данных Таблица 1 Сравнение характеристик наборов данных Характеристика BSTLD LISA Разрешение изображений 1280x720 1280x960 Количество классов 4 7 Объем обучающей выборки 5093 10220 Объем тестовой выборки 8334 3348 Данные датасеты содержат разметку в виде ограничивающих рамок с указанием класса сигнала Пример исходного кадра из обучающей выборки в сложных условиях освещения приведён на рисунке 1 Рисунок 1 Исходный кадр из обучающей выборки В процессе разметки объединённой выборки был выделен следующий набор классов сигналов светофора red yellow green off Существенной проблемой при формировании обучающего набора стал естественный дисбаланс красные и зелёные сигналы присутствуют большую часть времени тогда как переходные фазы жёлтый и состояние off встречаются значительно реже Для снижения влияния дисбаланса применялась аугментация миноритарных классов и взвешивание функции потерь по классам Распределение количества примеров по категориям представлено на рисунке 2 Рисунок 2 Распределение примеров по категориям В результате объединения открытых и собственных датасетов удалось сформировать достаточно разнообразный и репрезентативный набор данных покрывающий как типичные так и сложные малоизученные сценарии Это создаёт предпосылки для последующего построения и проверки нейросетевой модели способной обобщать полученные знания на реальные условия эксплуатации Архитектура модели и математический аппарат В качестве базовой архитектуры выбрано семейство моделей YOLOv8 одноэтапный детектор без использования якорных рамок Модель состоит из 1 Backbone для извлечения признаков 2 Neck FPN PAN для их 3 агрегации на разных масштабах и Head для предсказания 4 координат рамки и вероятности 5 класса Оптимизация модели в процессе обучения производится путем минимизации комплексной функции потерь которая состоит из трёх компонентов 1 LLYYYYYYYYYY8 cccccLLcccc bbbbbbLLbox 1 cLLdfl где Ltotal общая суммарная функция потерь общая ошибка модели за эпоху или батч Lbox потери по локализации насколько предсказанные координаты bounding box близки к реальной разметке Lcls потери по классификации ошибки в определении типа сигнала red yellow green off Ldfl потери по распределению границ рамки Distribution Focal Loss помогает точнее регулировать размытие координат рамки для маленьких объектов box cls dfl коэффициенты веса гиперпараметры которые задают насколько важна каждая часть локализация классификация распределение В общем виде взвешенная кросс энтропия для истинного класса используется для устранения дисбаланса классов 2 CE ppth ttlog ppth 2 где CE ppth взвешенная кросс энтропия для истинного класса на одном примере ppth вероятность от 0 до 1 с которой модель предсказала истинный правильный класс для данного объекта tt вес класса коэффициент который можно поднять для миноритарных классов например yellow и off log ppth натуральный логарифм или логарифм по

основанию 2 в зависимости от реализации но смысл тот же Использование архитектуры YOLOv8 в сочетании с гибкой настройкой функции потерь позволяет совместить высокую точность детекции малоразмерных объектов с требованиями к быстродействию предъявляемым к бортовым системам автономного транспорта Выбранные компоненты комплексной функции потерь нацелены на баланс между точностью позиционирования и правильной классификацией сигнала светофора Обучение модели и оценка качества Обучение проводилось на протяжении 64 эпох с динамическим снижением шага обучения от 0.00047 до 0.000058 График изменения функции потерь в процессе обучения приведён на рисунке 3 Рисунок 3 Изменение функции потерь в процессе обучения Для оценки точности локализации и классификации использовались метрики Precision точность Recall полнота и Mean Average Precision mAP Метрика mAP усредняет значения средней точности по всем классам при различных порогах перекрытия IoU от 0.50 до 0.95 Интегральная метрика mAP 50-95 вычисляется по формуле 3 Сумма идёт по 10 порогам TT 0.5 0.55 0.6 0.65 0.7 0.75 0.8 0.85 0.9 0.95 9 mAP50-95 mAP0.50-0.95

Здесь mAP50-95 значение метрики mean Average Precision усреднённое по десяти порогам перекрытия IoU от 0.50 до 0.95 с шагом 0.05 mAP TT обозначает значение mAP рассчитанное по всем классам при фиксированном пороге IoU TT Множитель соответствует простому усреднению по этим десяти значениям что позволяет получить интегральную характеристику качества детектора при разных уровнях строгости к совпадению предсказанных и истинных ограничивающих рамок где mAP50-95 средняя средняя точность mean Average Precision по диапазону порогов перекрытия IoU от 0.5 до 0.95 mAP TT средняя точность по всем классам при пороге IoU T то есть считается отдельно для каждого класса и затем усредняется Коэффициент это простое усреднение по 10 порогам то есть получается интегральная метрика отражающая производительность модели при разных уровнях строгости от слабого перекрытия до очень точного Динамика обучения показывает отсутствие переобучения ошибки на валидационной выборке стабильно снижались вместе с ошибками на тренировочном наборе Динамика изменения метрик в процессе обучения показана на рисунке 4 Рисунок 4 Динамика изменения метрик в процессе обучения Количественные результаты работы модели на финальной 64-й эпохе сведены в таблицу 2 Таблица 2 Метрики качества модели на 64-й эпохе обучения

Метрика	Значение на обучающей выборке	Значение на валидационной выборке
Ошибка локализации box loss	0.57792	0.68844
Ошибка классификации cls loss	0.33153	0.34535
Ошибка распределения границ dfl loss	0.89995	0.90337
Точность Precision	0.97977	
Полнота Recall	0.98175	
mAP 50	0.99249	
mAP 50-95	0.79718	

Модель достигла показателя mAP 50 на уровне 0.99249 а интегральная метрика mAP 50-95 составила 0.79718 Применение алгоритма Non Maximum Suppression NMS в сочетании с межкадровым трекингом позволило устранить дублирующие рамки и стабилизировать детекцию во времени Рисунок 5 Результаты детекции светофоров Приведённые результаты показывают что предложенная модель достигает высоких значений метрик как на обучающей так и на валидационной выборках при этом отсутствуют признаки переобучения Таким образом алгоритм может рассматриваться как перспективная основа для интеграции в систему автономного вождения требующая лишь дальнейшей оптимизации и адаптации к целевому вычислительному оборудованию Заключение Использование модуля детекции светофоров в общем пайплайне системы автономного вождения позволяет передавать точные координаты и фазу сигнала в модуль планирования движения Motion Planning Разработанная модель продемонстрировала высокую точность и

стабильность сбалансированная архитектура YOLOv8 и применение специфических функций потерь DFL и CloU обеспечили высокое качество детекции малоразмерных объектов без потери скорости инференса В дальнейшем планируется расширение обучающей выборки контекстными данными HD карт и квантизация модели для оптимизации вычислений на edge устройствах Предложенный модуль детекции светофоров демонстрирует потенциал для практического применения в системах автономного движения сочетая высокую точность с реалистичной скоростью инференса В перспективе развитие работы связано с улучшением отказоустойчивости в экстремальных условиях расширением классового множества и адаптацией модели под конкретные edge платформы что позволит повысить безопасность и комфорт эксплуатации автономного транспорта

Список литературы

- 1 Redmon J You only look once Unified real time object detection J Redmon S Divvala R Girshick A Farhadi Proceedings of the IEEE conference on computer vision and pattern recognition 2016 P 779 788
- 2 Jocher G YOLO by Ultralytics G Jocher A Chaurasia J Qiu 2023
- 3 Behrendt K A deep learning approach to traffic lights Detection tracking and classification K Behrendt L Novak R Botterweck 2017 IEEE International Conference on Robotics and Automation ICRA 2017 P 1370 1377
- 4 Jensen M B Vision for looking at traffic lights Issues survey and perspectives M B Jensen M P Philipsen A Møgelmoose T B Moeslund M M Trivedi IEEE Transactions on Intelligent Transportation Systems 2016 Vol 17 7 P 1800 1815
- 5
- 6
- 7
- 8
- 9
- 10

SEO-анализ текста

Заспамленность:	59%
Вода:	6%
Символы (с пробелами):	10 903
Символы (без пробелов):	9 516
Слова:	1 405
Заспамленность:	59% - Средняя
Водность:	6% - Низкая

Текст документа

УДК 004 932 2 629 3 05 РАЗРАБОТКА АЛГОРИТМА ДЕТЕКЦИИ СВЕТОФОРОВ И РАСПОЗНАВАНИЕ ИХ СИГНАЛОВ ДЛЯ АВТОНОМНОГО ТРАНСПОРТА Аннотация В статье рассматривается разработка легковесной модели детекции и классификации сигналов светофора для интеграции в систему автономного вождения ADAS Представлено полное

описание последовательности обработки видеопотока методов компенсации дисбаланса классов и архитектуры системы на основе YOLOv8. Проведена оценка качества на агрегированном датасете продемонстрировавшая высокую точность работы алгоритма. Результаты могут быть использованы для оптимизации ИТ решений в автомобильной промышленности. Ключевые слова: детекция светофоров, автономный автомобиль, компьютерное зрение, YOLO, дисбаланс классов, машинное обучение. Введение. Детекция светофоров и точное распознавание их сигналов являются критически важными компонентами системы восприятия мозга автономного автомобиля. В контексте оценки дорожной ситуации светофоры выступают ключевым регулятором проезда перекрестков. Данная задача отличается высокой сложностью из-за малого относительного размера объектов в кадре, изменчивых погодных условий, перекрытий и сильных визуальных искажений, засветки блики. Для обеспечения безопасности стандартов ADAS автомобилю необходимо не только фиксировать красный сигнал, но и уверенно распознавать разрешающие фазы для своевременного маневрирования. Целью данной работы является разработка и оптимизация нейросетевой модели детекции светофоров, способной функционировать в реальном времени на бортовом вычислителе. Детекция и распознавание сигналов светофоров представляют собой ключевое звено в системе восприятия автономного автомобиля, требующее одновременной точности по локализации, устойчивости к внешним факторам и высокой скорости обработки. В данной работе рассматривается возможность построения компактного и производительного алгоритма, ориентированного на работу в реальных дорожных условиях. Постановка задачи и обзор датасетов. На вход системы подается видеопоток с фронтальной камеры автомобиля. Алгоритм должен локализовать светофор, определить ограничивающую рамку, определить тип сигнала, осуществить межкадровый трекинг и передать результат в модуль принятия решений. Для обучения использовалась агрегированная выборка, включающая открытые датасеты Bosch Small Traffic Lights Dataset, BSTLD и LISA Traffic Light Dataset, а также собственные данные для покрытия сложных условий: ночь, блики. В таблице 1 представлено сравнение использованных открытых наборов данных. Таблица 1. Сравнение характеристик наборов данных.

Характеристика	BSTLD	LISA	Разрешение изображений	1280x720	1280x960	Количество классов	
4	7	Объем обучающей выборки	5093	10220	Объем тестовой выборки	8334	3348
Данные датасеты содержат разметку в виде ограничивающих рамок с указанием класса сигнала.							

Пример исходного кадра из обучающей выборки в сложных условиях освещения приведен на рисунке 1. Рисунок 1. Исходный кадр из обучающей выборки. В процессе разметки объединённой выборки был выделен следующий набор классов сигналов светофора: red, yellow, green, off. Существенной проблемой при формировании обучающего набора стал естественный дисбаланс: красные и зелёные сигналы присутствуют большую часть времени, тогда как переходные фазы жёлтый и состояние off встречаются значительно реже. Для снижения влияния дисбаланса применялась аугментация миноритарных классов и взвешивание функции потерь по классам. Распределение количества примеров по категориям представлено на рисунке 2. Рисунок 2. Распределение примеров по категориям. В результате объединения открытых и собственных датасетов удалось сформировать достаточно разнообразный и репрезентативный набор данных, покрывающий как типичные, так и сложные малоизученные сценарии. Это создаёт предпосылки для последующего построения и проверки нейросетевой модели, способной обобщать полученные знания на реальные условия эксплуатации.

Архитектура модели и математический аппарат. В качестве базовой архитектуры выбрано семейство моделей YOLOv8 одноэтапный детектор без использования якорных рамок. Модель состоит из Backbone для извлечения признаков, Neck FPN PAN для их агрегации на разных масштабах и Head для предсказания координат рамки и вероятности класса. Оптимизация модели в процессе обучения производится путем минимизации комплексной функции потерь, которая состоит из трёх компонентов: $L_{total} = L_{box} + L_{cls} + L_{lcl}$, где L_{total} — общая суммарная функция потерь, L_{box} — потеря, связанная с локализацией, L_{cls} — потеря по классификации, L_{lcl} — потеря по локализации. L_{box} близка к реальной разметке, L_{cls} — потеря по классификации ошибки в определении типа сигнала (red, yellow, green, off). L_{lcl} — потеря по распределению границ рамки. Distribution Focal Loss помогает точнее регулировать размытие координат рамки для маленьких объектов. box, cls, dfl — коэффициенты веса гиперпараметры, которые задают, насколько важна каждая часть локализации, классификация, распределение. В общем виде взвешенная кросс-энтропия для истинного класса используется для устранения дисбаланса классов. $CE = -\sum p_i \log p_i$, где p_i — вероятность от 0 до 1, с которой модель предсказала истинный правильный класс для данного объекта. tt — вес класса, коэффициент, который можно поднять для миноритарных классов, например, yellow и off. $\log$ — натуральный логарифм или логарифм по основанию 2, в зависимости от реализации, но смысл тот же. Использование архитектуры YOLOv8 в сочетании с гибкой настройкой функции потерь позволяет совместить высокую точность детекции малоразмерных объектов с требованиями к быстродействию, предъявляемым к бортовым системам автономного транспорта. Выбранные компоненты комплексной функции потерь нацелены на баланс между точностью позиционирования и правильной классификацией сигнала светофора. Обучение модели и оценка качества. Обучение проводилось на протяжении 64 эпох с динамическим снижением шага обучения от 0.00047 до 0.000058. График изменения функции потерь в процессе обучения приведён на рисунке 3. Рисунок 3. Изменение функции потерь в процессе обучения. Для оценки точности локализации и классификации использовались метрики Precision, точность, Recall, полнота и Mean Average Precision (mAP). Метрика mAP усредняет значения средней точности по всем классам при различных порогах перекрытия IoU от 0.50 до 0.95. Интегральная метрика mAP 50-95 вычисляется по формуле: $mAP_{50-95} = \frac{1}{10} \sum_{t=0.5}^{0.95} mAP_t$, где t — порог. TT — 0.5, 0.55, 0.6, 0.65, 0.7, 0.75, 0.8, 0.85, 0.9, 0.95. mAP50 — 95, mAP0.50 — 0.05, k — 3, k — 0. Здесь mAP50 — 95 — значение метрики mean Average Precision, усреднённое по десяти порогам перекрытия IoU от 0.50 до 0.95 с шагом 0.05. mAP TT обозначает значение mAP, рассчитанное по всем классам при фиксированном пороге IoU TT. Множитель соответствует простому усреднению по этим десяти значениям, что позволяет получить интегральную характеристику качества детектора при разных уровнях строгости к совпадению предсказанных и истинных ограничивающих рамок, где mAP50 — 95 — средняя средняя точность mean Average Precision по диапазону порогов перекрытия IoU от 0.5 до 0.95. mAP TT — средняя точность по всем классам при пороге IoU T, то есть считается отдельно для каждого класса и затем усредняется. Коэффициент — это простое усреднение по 10 порогам, то есть получается интегральная метрика, отражающая производительность модели при разных уровнях строгости от слабого перекрытия до очень точного. Динамика обучения показывает отсутствие переобучения, ошибки на валидационной выборке стабильно снижались вместе с ошибками на

тренировочном наборе Динамика изменения метрик в процессе обучения показана на рисунке 4 Рисунок 4 Динамика изменения метрик в процессе обучения Количественные результаты работы модели на финальной 64 й эпохе сведены в таблицу 2 Таблица 2 Метрики качества модели на 64 й эпохе обучения Метрика Значение на обучающей выборке Значение на валидационной выборке Ошибка локализации box loss 0 57792 0 68844 Ошибка классификации cls loss 0 33153 0 34535 Ошибка распределения границ dfl loss 0 89995 0 90337 Точность Precision 0 97977 Полнота Recall 0 98175 mAP 50 0 99249 mAP 50 95 0 79718 Модель достигла показателя mAP 50 на уровне 0 99249 а интегральная метрика mAP 50 95 составила 0 79718 Применение алгоритма Non Maximum Suppression NMS в сочетании с межкадровым трекингом позволило устранить дублирующие рамки и стабилизировать детекцию во времени Рисунок 5 Результаты детекции светофоров Приведённые результаты показывают что предложенная модель достигает высоких значений метрик как на обучающей так и на валидационной выборках при этом отсутствуют признаки переобучения Таким образом алгоритм может рассматриваться как перспективная основа для интеграции в систему автономного вождения требующая лишь дальнейшей оптимизации и адаптации к целевому вычислительному оборудованию Заключение Использование модуля детекции светофоров в общем пайплайне системы автономного вождения позволяет передавать точные координаты и фазу сигнала в модуль планирования движения Motion Planning Разработанная модель продемонстрировала высокую точность и стабильность сбалансированная архитектура YOLOv8 и применение специфических функций потерь DFL и CloU обеспечили высокое качество детекции малоразмерных объектов без потери скорости инференса В дальнейшем планируется расширение обучающей выборки контекстными данными HD карт и квантизация модели для оптимизации вычислений на edge устройствах Предложенный модуль детекции светофоров демонстрирует потенциал для практического применения в системах автономного движения сочетая высокую точность с реалистичной скоростью инференса В перспективе развитие работы связано с улучшением отказоустойчивости в экстремальных условиях расширением классового множества и адаптацией модели под конкретные edge платформы что позволит повысить безопасность и комфорт эксплуатации автономного транспорта Список литературы 1 Redmon J You only look once Unified real time object detection J Redmon S Divvala R Girshick A Farhadi Proceedings of the IEEE conference on computer vision and pattern recognition 2016 P 779 788 2 Jocher G YOLO by Ultralytics G Jocher A Chaurasia J Qiu 2023 3 Behrendt K A deep learning approach to traffic lights Detection tracking and classification K Behrendt L Novak R Botterweck 2017 IEEE International Conference on Robotics and Automation ICRA 2017 P 1370 1377 4 Jensen M B Vision for looking at traffic lights Issues survey and perspectives M B Jensen M P Philipsen A Møgelmo T B Moeslund M M Trivedi IEEE Transactions on Intelligent Transportation Systems 2016 Vol 17 7 P 1800 1815

Орфография

Ошибок найдено:	37
Орфографические:	36
Пунктуационные:	0
Грамматические:	0

Текст документа

УДК 004.932.2:629.3.05 РАЗРАБОТКА АЛГОРИТМА ДЕТЕКЦИИ СВЕТОФОРОВ И РАСПОЗНАВАНИЕ ИХ СИГНАЛОВ ДЛЯ АВТОНОМНОГО ТРАНСПОРТА Аннотация. В статье рассматривается разработка легковесной модели **детекции** 1 и классификации сигналов светофора для интеграции в систему автономного вождения (ADAS). Представлено полное описание последовательности обработки **видеопотока** 2, методов компенсации дисбаланса классов и архитектуры системы на основе YOLOv8. Проведена оценка качества на агрегированном **датасете** 3, продемонстрировавшая высокую точность работы алгоритма. Результаты могут быть использованы для оптимизации **ИТ-решений** 4 в автомобильной промышленности. Ключевые слова: **детекция** 5 светофоров, автономный автомобиль, компьютерное зрение, YOLO, дисбаланс классов, машинное обучение Введение. **Детекция** 6 светофоров и точное распознавание их сигналов являются критически важными компонентами системы восприятия ("мозга") автономного автомобиля. В контексте оценки дорожной ситуации светофоры выступают ключевым регулятором проезда перекрестков. Данная задача отличается высокой сложностью из-за малого относительного размера объектов в кадре, изменчивых погодных условий, перекрытий и сильных визуальных искажений (засветка, блики). Для обеспечения безопасности стандартов ADAS автомобилю необходимо не только фиксировать красный сигнал, но и уверенно распознавать разрешающие фазы для своевременного маневрирования. Целью данной работы является разработка и оптимизация **нейросетевой** 7 модели **детекции** 8 светофоров, способной функционировать в реальном времени на бортовом вычислителе. **Детекция** 9 и распознавание сигналов светофоров представляют собой ключевое звено в системе восприятия автономного автомобиля, требующее одновременной точности по локализации, устойчивости к внешним факторам и высокой скорости обработки. В данной работе рассматривается возможность построения компактного и производительного алгоритма, ориентированного на работу в реальных дорожных условиях. Постановка задачи и обзор **датасетов** 10. На вход системы подается видеопоток с фронтальной камеры автомобиля. Алгоритм должен локализовать светофор (определить ограничивающую рамку), определить тип сигнала, осуществить межкадровый трекинг и передать результат в модуль принятия решений. Для обучения использовалась агрегированная выборка, включающая открытые **датасеты** 11 Bosch Small Traffic Lights Dataset (BSTLD) и LISA Traffic Light Dataset, а также собственные данные для покрытия сложных условий (ночь, блики). В

таблице 1 представлено сравнение использованных открытых наборов данных. Таблица 1.

Набор данных	Разрешение изображений	Количество классов	Объем обучающей выборки	Объем тестовой выборки
Характеристика BSTLD LISA	1280x720	4	5093	10220
Данные датасеты 12	1280x960	7	8334	3348

Данные датасеты 12 содержат разметку в виде ограничивающих рамок с указанием класса сигнала. Пример исходного кадра из обучающей выборки в сложных условиях освещения приведен на рисунке 1. Рисунок 1. Исходный кадр из обучающей выборки В процессе разметки объединённой выборки был выделен следующий набор классов сигналов светофора: red, yellow, green, off. Существенной проблемой при формировании обучающего набора стал естественный дисбаланс: красные и зелёные сигналы присутствуют большую часть времени, тогда как переходные фазы (жёлтый) и состояние off встречаются значительно реже. Для снижения влияния дисбаланса применялась аугментация миноритарных 13 классов и взвешивание функции потерь по классам. Распределение количества примеров по категориям представлено на рисунке 2. Рисунок 2. Распределение примеров по категориям В результате объединения открытых и собственных датасетов 14 удалось сформировать достаточно разнообразный и репрезентативный набор данных, покрывающий как типичные, так и сложные, малоизученные сценарии. Это создаёт предпосылки для последующего построения и проверки нейросетевой 15 модели, способной обобщать полученные знания на реальные условия эксплуатации. Архитектура модели и математический аппарат. В качестве базовой архитектуры выбрано семейство моделей YOLOv8 (одноэтапный 16 детектор без использования якорных рамок). Модель состоит из Backbone для извлечения признаков, Neck (FPN/PAN) для их агрегации на разных масштабах и Head для предсказания координат рамки и вероятности класса. Оптимизация модели в процессе обучения производится путем минимизации комплексной функции потерь, которая состоит из трёх компонентов (1).

$$\mathcal{L}_{total} = \lambda_{l_{box}} \mathcal{L}_{box} + \lambda_{l_{cls}} \mathcal{L}_{cls} + \lambda_{l_{dfl}} \mathcal{L}_{dfl}, \quad (1)$$

где $\mathcal{L}_{total}$ - общая суммарная функция потерь ("общая ошибка" модели за эпоху 17 или батч); $\mathcal{L}_{box}$ - потери по локализации (насколько предсказанные координаты bounding-box близки к реальной разметке); $\mathcal{L}_{cls}$ - потери по классификации (ошибки в определении типа сигнала: red/yellow/green/off); $\mathcal{L}_{dfl}$ - потери по распределению границ рамки (Distribution Focal Loss, помогает точнее регулировать "размытие" координат рамки для маленьких объектов); λ_{box} , λ_{cls} , λ_{dfl} - коэффициенты-веса 19 (гиперпараметры), которые задают, насколько важна каждая часть: локализация, классификация, распределение. В общем виде взвешенная 20 кросс-энтропия для истинного класса используется для устранения дисбаланса классов (2).

$$CE(p_{gt}) = -\alpha_{gt} \log(p_{gt}), \quad (2)$$

где $CE(p_{gt})$ - взвешенная 21 кросс-энтропия для истинного класса на одном примере; p_{gt} - вероятность (от 0 до 1), с которой модель предсказала истинный (правильный) класс для данного объекта; α_{gt} - вес класса (22 коэффициент, который можно подбирать 23 для миноритарных классов, например yellow и off); $\log(p_{gt})$ - натуральный логарифм (или логарифм по основанию 2, в зависимости от реализации, но смысл тот же). Использование архитектуры YOLOv8 в сочетании с гибкой настройкой функции потерь позволяет совместить высокую 24 точность детекции малоразмерных объектов с требованиями к быстродействию, предъявляемым к бортовым системам автономного транспорта. Выбранные компоненты комплексной функции потерь нацелены на баланс между точностью позиционирования и правильной классификацией

сигнала светофора. Обучение модели и оценка качества. Обучение проводилось на протяжении 64 эпох с динамическим снижением шага обучения от 0.00047 до 0.000058. График изменения функции потерь в процессе обучения приведён на рисунке 3. Рисунок 3. Изменение функции потерь в процессе обучения

Для оценки точности локализации и классификации использовались метрики Precision (точность), Recall (полнота) и Mean Average Precision (mAP). Метрика mAP усредняет значения средней точности по всем классам при различных порогах перекрытия IoU от 0.50 до 0.95. Интегральная метрика $mAP@50-95$ вычисляется по формуле (3). Сумма идёт по 10 порогам: $TT = 0.5; 0.55; 0.6; 0.65; 0.7; 0.75; 0.8; 0.85; 0.9; 0.95$. $mAP50-95 = mAP0.50 + 0.05kk$ (3) $kk=0$ Здесь mAP50-95 - значение метрики mean Average Precision, усреднённое по десяти порогам перекрытия IoU от 0.50 до 0.95 с шагом 0.05; $mAP(TT)$ обозначает значение mAP, рассчитанное по всем классам при фиксированном пороге IoU TT . Множитель соответствует простому усреднению по этим десяти значениям, что позволяет получить интегральную характеристику качества детектора при разных уровнях строгости к совпадению предсказанных и истинных ограничивающих рамок где $mAP50-95 \leftarrow 25$ - средняя средняя точность (mean Average Precision) по диапазону порогов перекрытия IoU от 0.5 до 0.95; $mAPTT$ - средняя точность по всем классам при пороге IoU = T, то есть считается отдельно для каждого класса и затем усредняется. Коэффициент - это простое усреднение по 10 порогам, то есть получается интегральная метрика, отражающая производительность модели при разных уровнях строгости (от "слабого" перекрытия до очень точного). Динамика обучения показывает отсутствие переобучения: ошибки на валидационной выборке стабильно снижались вместе с ошибками на тренировочном наборе. Динамика изменения метрик в процессе обучения показана на рисунке 4. Рисунок 4. Динамика изменения метрик в процессе обучения

Количественные результаты работы модели на финальной 64-й эпохе сведены в таблицу 2. Таблица 2. Метрики качества модели на 64-й эпохе обучения

Метрика	Значение
Значение на обучающей выборке	0.57792
Значение на валидационной выборке	0.68844
Ошибка локализации (box_loss)	0.57792
Ошибка классификации (cls_loss)	0.68844
Ошибка распределения границ (dfl_loss)	0.33153
Точность (Precision)	0.97977
Полнота (Recall)	0.98175
mAP@50	0.99249
mAP@50-95	0.79718

Модель достигла показателя mAP@50 на уровне 0.99249, а интегральная метрика mAP@50-95 составила 0.79718. Применение алгоритма Non-Maximum Suppression (NMS) в сочетании с межкадровым трекингом позволило устранить дублирующие рамки и стабилизировать детекцию во времени. Рисунок 5. Результаты детекции светофоров

Приведённые результаты показывают, что предложенная модель достигает высоких значений метрик как на обучающей, так и на валидационной выборках, при этом отсутствуют признаки переобучения. Таким образом, алгоритм может рассматриваться как перспективная основа для интеграции в систему автономного вождения, требующая лишь дальнейшей оптимизации и адаптации к целевому вычислительному оборудованию. Заключение. Использование модуля детекции светофоров в общем пайплайне системы автономного вождения позволяет передавать точные координаты и фазу сигнала в модуль планирования движения (Motion Planning). Разработанная модель продемонстрировала высокую точность и стабильность: сбалансированная архитектура YOLOv8 и применение специфических функций потерь (DFL и Clou) обеспечили высокое качество детекции

малоразмерных объектов без потерь 35 и скорости инференса. В дальнейшем планируется расширение обучающей выборки контекстными данными HD-карт и квантизация модели для оптимизации вычислений на edge-устройствах. Предложенный 36 модуль детекции светофоров демонстрирует потенциал для практического применения в системах автономного движения, сочетая высокую точность с реалистичной 37 скоростью инференса. В перспективе развитие работы связано с улучшением отказоустойчивости в экстремальных условиях, расширением классового множества и адаптацией модели под конкретные edge-платформы, что позволит повысить безопасность и комфорт эксплуатации автономного транспорта. Список литературы [1] Redmon, J. You only look once: Unified, real-time object detection / J. Redmon, S. Divvala, R. Girshick, A. Farhadi // Proceedings of the IEEE conference on computer vision and pattern recognition. - 2016. - P. 779-788. [2] Jocher, G. YOLO by Ultralytics / G. Jocher, A. Chaurasia, J. Qiu. - 2023. [3] Behrendt, K. A deep learning approach to traffic lights: Detection, tracking, and classification / K. Behrendt, L. Novak, R. Botterweck // 2017 IEEE International Conference on Robotics and Automation (ICRA). - 2017. - P. 1370-1377. [4] Jensen, M. B. Vision for looking at traffic lights: Issues, survey, and perspectives / M. B. Jensen, M. P. Philipsen, A. Møgelmoose, T. B. Moeslund, M. M. Trivedi // IEEE Transactions on Intelligent Transportation Systems. - 2016. - Vol. 17(7). - P. 1800-1815.